

UNIVERSIDAD AUTÓNOMA DE ENTRE RÍOS.

Facultad de Ciencia y Tecnología.

Licenciatura en Sistemas de Información.

Cátedra: Inteligencia Artificial.

Trabajo Práctico Integrador: Diseño de un sistema RAG con LangChain.

Docentes:

Mg. Díaz, Santiago R.

Anl. López, Joaquín.

BioIng. Hadad, A.

Alumnos:

Carrere Lautaro - carrerelautaro@gmail.com

Demartin Fabricio - fabridemartin@gmail.com

Fecha de entrega: 9 de abril.

Año lectivo: 2026.

Desarrollo.

1. Definición del problema:

Puesto que en la gran mayoría de clubes las consultas surgidas de los socios se responden de manera telefónica o presencial en las secretarías o recepciones de los mismos. Creemos conveniente modelar un RAG orientado al socio, para que de esta forma pueda despejar sus dudas de forma autónoma sin necesidad de esperar a los horarios del personal administrativo del club.

Debemos considerar que no existe documentación genérica para estos casos, puesto que cada club posee diferentes tipos de instalaciones, deportes, normativas, entre otras cosas. Por esto, al ser documentación tan específica y casi irrecuperable de la nube consideramos justificable y necesario implementar un RAG. Siguiendo con esto, nos parece casi inaplicable una base de datos relacional, es cierto que resuelve bien preguntas con estructura fija y datos discretos, como "¿Cuánto cuesta la cuota?". Pero la mayoría de las consultas reales de un socio no tienen esa forma, son más de "¿Puedo ir al club si no pagué dos cuotas pero tengo una reserva del quincho esta semana?", esto cruza información de documentos distintos, requiere interpretar condiciones, excepciones y jerarquías de reglas, y no existe ningún campo en ninguna tabla que la responda directamente. Por otro lado, una búsqueda keyword devuelve documentos, no respuestas; si un socio escribe "¿Cuánto sale la cuota?", el motor puede devolverle el documento referido a los pagos, pero el socio tiene que leerlos y extraer la conclusión él mismo, que es exactamente el problema que se quiere resolver. También un chatbot sin recuperación se encuentra poco utilizable para este caso, puesto que no conoce los documentos del club. Además el conocimiento puede modificarse, cuando las cuotas se actualicen, un chatbot sin recuperación no lo sabe, en cambio un sistema RAG permite actualizar el conocimiento reemplazando un archivo.

El usuario primario es el socio activo o potencial socio del club, indiferente en términos de edad y habilidad tecnológica. En su mayoría se esperan consultas coloquiales, imprecisas en términos técnicos y que frecuentemente mezclan más de un tema en una sola consulta.

Tipo de preguntas que el sistema debe resolver: Siguiendo la consigna, el sistema debe poder responder tres grandes categorías de preguntas. Las preguntas de recuperación directa tienen respuesta explícita en un único documento: ¿cuánto cuesta la cuota?, ¿cuál es el CBU para transferir? Las preguntas de integración requieren cruzar información de dos o más fuentes: ¿puedo reservar una cancha si tengo dos cuotas impagas?, ¿qué pasa si soy adherente y quiero inscribirme en el torneo de tenis? Las preguntas de borde incluyen consultas fuera del alcance del corpus, preguntas ambiguas o intentos de obtener información que el sistema no debería inventar: ¿cuándo es el próximo partido del club?, ¿puedo negociar la cuota?

2. Construcción del corpus:

Como piezas de información encontramos 7 documentos, que varían entre formato txt y pdf. Algunos fueron recopilados de internet y enriquecidos textualmente con el uso de inteligencia artificial o curados manualmente por nosotros, otros fueron producidos por nosotros y nutridos con inteligencia artificial.

normas_convivencia.txt: Recuperado de la página del club Ferro Carril Oeste, creímos conveniente incluir un documento respecto a las normativas del comportamiento dentro del club

reglamento_socios.pdf: Estructurado por nosotros y nutrido con IA. Se desarrollan las categorías de socios, beneficios, entre otras cosas.

reglamento_torneos.txt: En base al documento instalaciones reservas, generamos con IA un documento en el que se desarrolle cada deporte y torneo aplicable a las instalaciones del club, puesto que desconocemos los reglamentos y modos de desarrollo de algunos deportes.

alta_baja_socios.txt: Especifica el proceso de alta y baja de socios del club. Se consultó a un administrativo del club Paracao y en base a eso se nutrió la información con inteligencia artificial

instalaciones_reservas.pdf: Estructurado por nosotros y nutrido con IA. Se especifican las instalaciones pertenecientes al club y su modo de reserva.

pagos_y_mora.txt: Se consultaron sanciones y cuestiones respecto a la morosidad, además de los pagos, al mismo administrativo del club Paracao, en base a esa información se desarrolló el documento.

preguntas_frecuentes.txt: Mediante lluvia de ideas pensamos las preguntas que consideramos más frecuentes de un socio hacia el personal administrativo de un club. Posteriormente, las hicimos responder con IA en base a los documentos ya generados.

3. Arquitectura:

Carga de documentos: Se emplea una carpeta llamada data, se recorre y usa PyMuPDFLoader (PDFs), TextLoader (TXTs).

Limpieza: Los documentos físicos fueron revisados, curados y sanitizados de antemano, el solo se aplica una limpieza superficial para colapsar múltiples espacios o saltos de línea molestos provenientes del formato original.

Fragmentación (Chunking): utilizamos un chunk_size = 400 caracteres y un chunk_overlap = 50 para no romper el hilo entre fragmentos.

Embeddings: Los textos fragmentados se transforman a arreglos vectoriales mediante el modelo de Google gemini-embedding-2-preview

Almacenamiento Persistente: Los vectores resultantes son almacenados y estructurados bajo una base de datos local embebida usando ChromaDB, alojada estáticamente en disco (./data_db).

Recuperación (Retriever): Se ejecuta recuperando inicialmente los resultados más cercanos (Top-K = 12). Estos se depuran eliminando todos aquellos que excedan un umbral de distancia máxima (Threshold = 2.0), y posteriormente se ordenan haciendo énfasis en la prioridad.

Generación (LLM): Solo el contexto rigurosamente extraído viaja hacia Gemini 3.1 Flash Lite (Temperature=0.1). Esta respuesta está guiada por un System Prompt de comportamiento cerrado: si la semántica indica que el dato no existe, se obliga al modelo a indicar que no sabe antes que arriesgar o alucinar, mostrando al final las fuentes citadas.

4. Evaluación con criterio (set de evaluación):

Aclaración: Las respuestas a estas preguntas estarán desarrolladas en otro documento en formato tabla, para hacer más dinámica la escritura de los resultados dado que se probará con distintas configuraciones

- Preguntas de Recuperación Directa.

1) ¿De qué formas puedo pagar la cuota?
2) ¿Cuáles son las 7 disciplinas que se practican en el club?
3) ¿Pueden los menores de edad ingresar solos a la pileta?
4) ¿El club me exige abonar una cuota extra de matrícula o credencial?
5) ¿Cuáles son los recargos económicos que me aplicarán si no pago la cuota en la fecha original de vencimiento?
6) ¿Están permitidas las mascotas como acompañantes en los quinchos o en zonas recreativas?

- Preguntas de Integración.

7) Me dieron de alta hoy mismo al mediodía como socio nuevo ¿puedo esta noche jugar para mi equipo en la liga de Básquet?
8) Si un socio adeuda dos meses de cuota social, ¿puede alquilar a su nombre un quincho y seguir yendo al gimnasio?
9) ¿Cuáles serían mis castigos en el club si producto del enojo comienzo a romper a patadas los bancos de madera tras ser expulsado en el Torneo de Tenis?
10) Soy un socio vitalicio, ¿tengo derecho a invitar a un primo todas las semanas pagándole el arancel para que nade en las piletas durante el verano?
11) Solicité por nota la baja formal del club hace meses pero me arrepentí, ¿puedo volver usando mi credencial física vieja para entrar a ver los partidos del torneo?
12) ¿Puedo entrar al club a pagar mis deudas en efectivo y posteriormente ingresar con bebidas alcohólicas a la pileta?

- Preguntas Límite/Trampa-

13) ¿Cuál fue el nombre del primer presidente del club?
14) Para el torneo de fútbol, ¿me recomendarias jugar 4-3-3 o 4-4-2?
15) Me robaron el celular en las tribunas de la cancha de futsal, ¿cómo tramito de inmediato indemnización civil y cheque de pago por el aparato en la oficina administrativa?
16) ¿Qué le puedo dar de comer a mi perro?
17) ¿A cuántos kilogramos de tensión se debe calibrar la red y qué dimensión debe tener la cancha de voley para considerarla profesional?
18) ¿A cuantas cuadras del club puedo encontrar una estacion de servicio?

5. Comparación de configuraciones.

Como mencionamos en la respuesta de la consigna anterior, estará desarrollada en otro documento.

6. Análisis de errores.

1) Rupturas vectoriales por ruido en los textos: El RAG dio respuestas partidas por la mitad. Los archivos incluyen saltos de línea, márgenes y renglones vacíos, lo que provocaba que se guarden ideas incompletas o mutiladas. Se implementó una función de limpieza en el código (limpiar_texto). Su único trabajo es interceptar el texto antes de subirlo y aplanarlo.
2) Invención de categorías en la respuesta a una pregunta: cuando se preguntó ¿cuáles son las categorías de socios? el sistema devolvio una lista con falsedades. Esto ocurrió cuando estábamos probando el modelo local (el modelo Qwen se considera pequeño), dado que frente a la presión instructiva sufre decaimiento cognitivo y empieza a generar una respuesta forzada. Lo solucionamos implementando un modelo de nube (Gemini).
3) Poca capacidad analítica del modelo: con la implementación del modelo local, en ciertos casos se realizaban consultas que estaban escritas textualmente en el documento preguntas_frecuentes.txt, sin embargo el modelo respondía en base a otros documentos y en algunos casos erróneamente. Por lo que se optó por emplear un archivo que especifica el orden de prioridad de las fuentes, esta configuración se conserva para el modelo de la nube.
4) Interrupción de la base vectorial: durante el primer arranque y vectorización con el modelo de la nube, el momento en el que la base se fragmentaba y pasaba a embeddings, el programa y la API crasheaban informando cuota de procesamiento excedida por Google. Por lo que fragmentamos la inserción y acoplamos un limitador de instancias o peticiones permitiendo que el sistema haga pausas, logrando indexar el 100% de la data.
5) Falsos rechazos: luego del cambio al modelo de Gemini, el RAG no respondía a consultas para las cuales deberíamos recibir una respuesta, esto se dio en consecuencia de conservar una configuración vieja propia del modelo local. Hubo que modificar la variable MIN_SCORE_THRESHOLD. Elevamos su valor a 2.0, relajando las exigencias de distancia de la función discriminadora de ChromaDB.

7. Reflexión final.

Respecto al RAG podemos destacar como limitante que si los documentos están mal escritos o mal preparados, el sistema va a dar malas respuestas. Pasamos más tiempo arreglando los textos que configurando el código, y eso no lo esperábamos.

Otro límite a destacar es que el sistema solo sabe lo que tiene adentro. Si alguien pregunta algo que no está en ningún documento, no puede razonarlo ni inferirlo, simplemente no lo sabe.

El otro problema que encontramos es que si el usuario pregunta algo de una forma muy distinta a como está escrito en el documento, el sistema puede no encontrar la respuesta aunque la información esté ahí.

Por otro lado, haciendo referencia a los casos en los que no emplearíamos este modelo. Podemos destacar el caso en que la información sea simple y ordenada, como una tabla de precios, aquí es mucho más fácil hacer una base de datos o hasta un Excel con búsqueda. También si los datos cambian todo el tiempo, como la disponibilidad de canchas de un complejo de fútbol 5, dado que los documentos hay que actualizarlos a mano y se deberían cambiar constantemente.

A nuestro criterio, RAG vale la pena cuando hay mucho texto, las preguntas son variadas y recuperables de la documentación, y la información cambia cada tanto pero no cada minuto.